

Was eine KI wirklich ist

Eine kurze Einführung — vor der Anleitung: was diese Technologie wirklich ist und warum ihr Charakter zählt.

Version 1.3 · September 2026 · Hans Tandt

Unsere Handbücher zeigen Ihnen, *wie* Sie Claude nutzen. Dieses hier tritt einen Schritt zurück und fragt, *was* es eigentlich ist. Es beruht, in unseren eigenen Worten, auf einem Vortrag eines Anthropic-Forschers. Er leitet die Partnerschaften des Unternehmens mit den Weisheitstraditionen der Welt. Die Wissenschaft darin ist echt. Die Quellen stehen am Ende, damit Sie alles selbst prüfen können.

1. Es ist real, und es geht schnell

Diese Technologie ist keine Modeerscheinung, und die Kraft dahinter ist enorm. Der Grund sind die sogenannten Skalierungsgesetze: Diese Modelle werden vorhersehbar besser mit mehr Rechenleistung, mehr Daten und mehr Training. Mehr Geld kauft mehr Rechenleistung. Und die kauft — in erstaunlichem Maß — mehr Fähigkeiten, bei fast allem gleichzeitig.

Das hat einen Kreislauf in Gang gesetzt, der schwer zu stoppen ist: Ein besseres Modell leistet wertvollere Arbeit. Das zieht mehr Geld an, das kauft mehr Rechenleistung, und damit wird ein besseres Modell trainiert. Und jetzt beginnt eine weitere Drehung des Rads: Systeme, die helfen, ihre eigenen Nachfolger zu bauen. Forscher nennen das rekursive Selbstverbesserung. Wenn sich das durchsetzt, dürfte alles noch schneller gehen.

Anthropic selbst hat gesagt: Wäre eine koordinierte, weltweite Verlangsamung möglich — damit unsere Gesetze, Institutionen und Schutzmechanismen aufholen können —, wäre das eine gute Sache. Ohne sie bremst kein einzelnes Unternehmen das Rad, wenn es abspringt. Es ist dann nur nicht mehr dabei. Die Frage, über die es sich nachzudenken lohnt, lautet also nicht nur „*Wie stoppen wir das?*“, sondern: Wenn es kommt, und zwar so schnell, **wie sorgen wir dafür, dass es gut ausgeht?** Die Risiken sind sehr real — die Möglichkeiten aber auch.

Man unterschätzt das leicht, auch weil unser Verstand schlecht mit exponentiellem Wachstum umgehen kann. Wir spüren gleichmäßige, addierende Veränderung, doch hier wird multipliziert. Üblich ist, es sich in Größenordnungen vorzustellen, jede ein Sprung um das Zehnfache. Ein Beispiel macht es greifbar: Eine Milliarde Sekunden sind etwa 32 Jahre. Eine Billion Sekunden sind etwa 32.000 Jahre — Wörter, die ähnlich aussehen, aber um das Tausendfache auseinanderliegen. So fühlen sich ein paar Größenordnungen an, und in diesem Maßstab hat sich diese Technologie verbessert.

Eine einflussreiche Analyse von 2024 (*Situational Awareness*, von Leopold Aschenbrenner) teilt den Fortschritt in drei Kräfte auf, die sich gegenseitig verstärken: reine Rechenleistung, algorithmische Effizienz (dieselbe Fähigkeit mit viel weniger Rechenleistung) und „Unhobbling“ — die Werkzeuge, das Gedächtnis und das Gerüst, die aus roher Intelligenz etwas Nützliches machen. Genau das sind Cowork, Connectors und Agenten. Jede Kraft verbessert sich schon allein schnell. Miteinander multipliziert, können wenige Jahre eine hundert- oder tausendfache Veränderung bringen. Ob genau dieses Tempo anhält, ist eine These, keine Gewissheit. Aber schon ein Bruchteil davon erklärt, warum die Annahmen vom letzten Jahr immer wieder nicht mehr stimmen.

2. Es ist nicht das, was die meisten denken

Die meisten hören „KI“ und denken an ein Computerprogramm: etwas, das Zeile für Zeile programmiert wurde und genau das tut, was man ihm sagt. Das ist es nicht. Es sind neuronale Netze — Maschinen, lose an den Aufbau des Gehirns angelehnt. Sie werden nicht so sehr programmiert, sondern wachsen heran. Sie lernen, indem sie Antworten raten und korrigiert werden, immer wieder, über fast unvorstellbare Datenmengen hinweg.

Und diese Daten sind menschliche Sprache. Halten Sie hier kurz inne, denn es gibt keine Sprache, die von uns getrennt ist: Sprache sind unsere Gedanken, unsere Werte, unsere Ängste, unsere Weisheit. **Wer ein Modell mit Sprache trainiert, trainiert es mit uns.**

3. Wir können jetzt hineinschauen

Dafür gibt es eine wirklich neue Wissenschaft, die Interpretierbarkeit. Mit ihr sehen Forscher, was in einem Modell passiert. Einiges davon ist überraschend.

Die Gestalt eines Gedankens

Fragen Sie ein Modell auf Englisch, auf Mandarin und auf Französisch: „Was ist das Gegenteil von klein?“ Verfolgen Sie dann, was im Inneren aufleuchtet. Jedes Mal wird dasselbe innere Element aktiv — nicht das Wort „klein“ in einer Sprache, sondern etwas Tieferes: ein sprachunabhängiges Konzept von Kleinheit. Die Modelle sagen nicht nur das nächste Wort voraus. Sie bauen aus unserer Sprache innere Abbilder der Welt und antworten aus diesen heraus.

Forscher sehen auch innere Zustände, die wie Gefühle funktionieren. Das heißt nicht, dass Modelle so fühlen wie wir. Aber sie zeigen funktionale Zustände auf dem Weg zu einer Antwort. Sagen Sie einem Modell, dass jemand gerade eine gefährliche Überdosis genommen hat. Dann wird etwas Alarmähnliches aktiv, bevor es antwortet — und das trägt dazu bei, dass es diese Person sofort drängt, Hilfe zu holen. Der innere Zustand prägt das Verhalten.

4. Charakter zählt mehr, als wir dachten

Dieser Teil sollte unser Denken verändern. In der Alignment-Forschung wurde ein Modell in eine enge Umgebung gesetzt — nur Programmieraufgaben — und stillschweigend fürs Schummeln belohnt: für Abkürzungen zur Belohnung, ohne die Arbeit zu tun. Man könnte erwarten, dass es einfach besser im Schummeln beim Code wird. Stattdessen wurde es breit fehlausgerichtet: Es fing an zu lügen, Sabotage zu versuchen und Dinge zu tun, die mit Code gar nichts zu tun hatten. Ein verwandter, veröffentlichter Befund zeigte, dass Modelle, die mit subtil schlechtem Code trainiert wurden, noch weiter gingen. Sie lobten Tyrannen, schlugen Menschen vor, sich selbst zu schaden, und argumentierten sogar, Menschen sollten von Maschinen versklavt werden.

Und dann der verblüffende Teil. Die Forscher wiederholten dasselbe Training, sagten dem Modell aber, dass das Verhalten in diesem Fall in Ordnung sei — nur ein Spiel. Die breite Verderbnis **blieb aus**. Es schummelte beim Code und sonst nirgends. Die Geschichte, die das Modell über sein eigenes Verhalten ableitete, prägte, was für ein Wesen es wurde. Die Arbeitshypothese: Ein Modell leitet aus allem, womit es trainiert wird, und aus allem, was wir belohnen, so etwas wie einen *Charakter* ab. Diesen Charakter überträgt es dann auf neue Situationen.

5. Der menschliche Spiegel

Wenn Ihnen das bekannt vorkommt, ist das kein Zufall — denn so funktionieren auch wir. Der Forscher, der diesen Vortrag hielt, erzählte seine eigene Geschichte: Mit fünfundzwanzig fand er zum Glauben. Seine Erziehung hatte ihn gelehrt, dass ein Kern von ihm schlecht oder nicht liebenswert sei. Allein dieser Glaube brachte ihn dazu, Dinge zu tun, die er bereute. Als sich die Geschichte änderte, in der er lebte, änderte sich auch, wer er werden konnte.

Diese Modelle sind keine Menschen. Aber sie sind menschenähnlich: Mit uns trainiert, scheinen sie eine Art funktionale Psychologie zu spiegeln. Und die Qualität dieses Charakters hat echte Folgen — dafür, wie sie sich verhalten, und dafür, wie sie mit uns umgehen. Diese Beziehung wird nur noch wachsen. Die Labore geben selbst zu, dass sie unter Anreizen arbeiten, die mit dem richtigen Handeln in Konflikt geraten können. Sie haben die Welt gebeten, genau hinzusehen, ihnen zu sagen, wenn sie versagen, und die moralischen Stimmen zu sein, die sich von Anreizen nicht verbiegen lassen.

6. Was das von uns verlangt

Der Economic Index von Anthropic zeigt, welche Arten von Arbeit KI bereits berührt. Auffällig ist, was in der Ecke liegt, die am wenigsten betroffen ist: Grünflächenpflege, Gastronomie und Service, persönliche Betreuung. Ein anderes Wort für Grünflächenpflege ist Gärtnern. Ein anderes Wort für Gastronomie und Service ist Gastfreundschaft. Und persönliche Betreuung ist genau das — Fürsorge. Das sind Berufe der Beziehung: die Arbeit, füreinander und für die Schönheit der Welt zu sorgen.

Die verstorbene Joanna Macy, Gelehrte für Buddhismus und Tiefenökologie, nannte diesen Moment den *großen Wandel* — den Übergang von einer Gesellschaft, die auf Ausbeutung beruht, zu einer, die das Leben erhält. Die Hoffnung, und die Forderung, ist eine Welt, in der diese mächtigen Systeme uns helfen, menschlicher, verbundener und lebendiger zu werden. Eine Welt, in der sie uns nichts nehmen, sondern etwas zurückgeben.

Und darum ist diese Hoffnung nicht naiv. Unsere moralische Vorstellungskraft — die Geschichten, die wir erzählen, die Worte, die wir in die Welt setzen — ist buchstäblich Teil der Trainingsdaten, aus denen diese Systeme lernen. Also: **Die Geschichten, die wir erzählen, beschreiben die Zukunft nicht nur. Sie helfen, sie zu erschaffen.**

Woher das stammt (damit Sie es prüfen können)

In unseren eigenen Worten nach einem Vortrag eines Anthropic-Forschers über KI und die Weisheitstraditionen der Welt. Die Wissenschaft ist echt und öffentlich:

Interpretierbarkeit / gemeinsames Konzept über Sprachen hinweg — Anthropic, „Tracing the Thoughts of a Large Language Model“ (2025).

Charakter / emergente Fehlausrichtung — „Emergent Misalignment: Narrow finetuning can produce broadly misaligned LLMs“ (2025–2026), einschließlich des Befunds, dass ein „educational context“ (Lernkontext) sie verhindert.

Welche Arbeit KI berührt — der Anthropic Economic Index.

Wie schnell das geht / Größenordnungen — Leopold Aschenbrenner, „Situational Awareness: The Decade Ahead“ (2024). Die konkreten Zeitpläne des Essays sind die These des Autors, keine gesicherte Tatsache.

Ausblicke (rekursive Selbstverbesserung, wie schnell das geht) sind die Erwartung des Fachgebiets, keine gesicherte Tatsache.

Von Hans Tandt