

Das richtige Claude-Modell wählen

Ein Praxisleitfaden: welches Modell Sie nutzen, warum es kostet, was es kostet, und wie die Limits wirklich funktionieren

Version 1.3 · 28. September 2026



Inhaltsverzeichnis

1. Zweck dieses Leitfadens.....	3
2. Die schnelle Regel und was sie auslsst.....	3
3. Die aktuellen Modelle im berblick.....	4
4. Schnelle Entscheidungshilfe.....	4
5. Warum sich ein bewusster Modellwechsel lohnt.....	4
6. Was ist ein Token?.....	5
7. Token- und Rechenkosten.....	5
8. Abos: private Konten und Firmenkonten.....	6
8.1 Private Abos (Einzelpersonen).....	6
8.2 Firmen-Abos (Unternehmen).....	6
9. Sitzungslimits, Wochenlimits und woher die Reset-Uhr kommt.....	7
10. Modelle ndern sich, und neuere knnen ein Kontingent schnell aufbrauchen.....	7
11. Selbstlaufende Agenten: warum die Monatsrechnung schneller steigen kann als erwartet.....	8
12. Was Sie sonst noch wissen sollten.....	8

HINWEIS — Erstellt am 5. September 2026 - zuletzt aktualisiert am 28. September 2026

Modellnamen, Preise und Limits ändern sich oft. Die Angaben hier wurden zum Stand der letzten Aktualisierung mit der offiziellen Dokumentation von Anthropic abgeglichen. Prüfen Sie claude.com/pricing und platform.claude.com/docs, bevor Sie sich auf genaue Zahlen verlassen.

1. Zweck dieses Leitfadens

Dieser Leitfaden hilft Ihnen, das richtige Claude-Modell zu wählen. Er erklärt auch, was hinter dieser Wahl steckt: warum sie wichtig ist, was ein Token eigentlich ist, wie aus Tokens Kosten werden, wie sich private und Firmen-Abos von Claude unterscheiden und wie die Nutzungslimits und ihre Resets wirklich funktionieren. Am Ende steht eine kurze Liste mit Punkten, die eine schnelle Entscheidungsgrafik meist auslöst.

2. Die schnelle Regel und was sie auslöst

Beliebt ist ein einfacher Entscheidungsbaum (eine viel geteilte Version ist eine Infografik von Dr. Joerg Storm auf LinkedIn; sie stammt nicht von Anthropic): Für eine schnelle Antwort wählen Sie Haiku für Tempo oder Sonnet für bessere Qualität. Für alles Schwierigere wählen Sie Opus für eine einzelne schwere Denkaufgabe oder Fable für Arbeit über viele Schritte und Tools hinweg.

Diese Logik hält dem Vergleich mit den Empfehlungen von Anthropic (Stand September 2026) gut stand. Die vier Modellfamilien gibt es, und die Reihenfolge entspricht der Darstellung von Anthropic: Haiku am schnellsten und günstigsten, Sonnet mit der besten Mischung aus Tempo und Intelligenz, Opus für anspruchsvolle Arbeit (Anthropic empfiehlt inzwischen, für die meisten Aufgaben mit Opus zu beginnen) und Fable für das anspruchsvollste Denken und lange, toolintensive agentische Arbeit. Einige Punkte sind aber zu ergänzen.

- Versionsnummern fehlen, und sie sind wichtig. Zum Zeitpunkt dieses Textes sind die aktuellen Versionen Haiku 4.5, Sonnet 5, Opus 5.5 und Fable 5.1. Jede neue Version verschiebt, was „gut genug“ bedeutet. „Nutzen Sie Sonnet“ heißt also eigentlich „Nutzen Sie das jeweils aktuelle Sonnet“.
- Fable ist nicht in jedem Abo enthalten, und es ist begrenzt. Es ist ab Pro enthalten (Pro, Max, Team und Enterprise), darf bei Pro und Max aber höchstens etwa die Hälfte Ihrer Wochenlimits verbrauchen. Das Free-Abo bietet nur Haiku und Sonnet.
- Keine Angaben zu Kosten. Die Grafik zeigt nur die Abwägung zwischen Tempo und Qualität. Zum Preis sagt sie nichts, und der unterscheidet sich zwischen dem günstigsten und dem teuersten Modell um bis zu das 10-Fache.
- Erweitertes oder adaptives Denken ist ein eigener Hebel, unabhängig von der Modellwahl. Wenn Sie erhöhen, wie viel ein Modell vor der Antwort nachdenkt, steigen Qualität und Kosten, egal welches der vier Modelle Sie gewählt haben.

Die praktische Regel hinter jeder solchen Grafik ist richtig: Nutzen Sie das leichteste Modell, das die Aufgabe zuverlässig erledigt. Wechseln Sie nur nach oben, wenn die Aufgabe selbst komplexer, unklarer oder wichtiger wird, nicht aus Gewohnheit.

3. Die aktuellen Modelle im Überblick

Modell	Am besten geeignet für	Kontextfenster	Relative Kosten
Haiku 4.5	Schneller Chat, Zusammenfassungen, erste Entwürfe, Aufgaben in großer Menge oder mit wenig Budget	200K Tokens	Am niedrigsten
Sonnet 5	Schnelle Alltagsarbeit: Schreiben, Analyse, Planung, die meisten Büroaufgaben und Programmieren	1M Tokens	Niedrig bis mittel
Opus 5.5	Anspruchsvolle Arbeit, schwieriges Denken, feine Abwägungen und langes agentisches Programmieren; der von Anthropic empfohlene Einstieg	1M Tokens	Mittel
Fable 5.1	Lange, mehrstufige, toolintensive agentische Arbeit und Orchestrierung; für die schwierigsten 10 % reservieren	1M Tokens	Am höchsten

HINWEIS — Die Kontextfenster unterscheiden sich je nach Modell

Haiku behält das ältere Kontextfenster mit 200K; Sonnet, Opus und Fable bieten derzeit 1M Tokens. Aktuelle Werte finden Sie unter platform.claude.com/docs/en/models.

4. Schnelle Entscheidungshilfe

Situation	Modell	Warum
Eine schnelle Information, Zusammenfassung oder ein erster Entwurf	Haiku	Am schnellsten und günstigsten; für Texte mit wenig Tragweite mehr als gut genug
Alltägliches Schreiben, Analyse, Planung, das meiste Programmieren	Sonnet	Beste Balance aus Qualität und Kosten; die sinnvolle Standardwahl für ein Team
Die Aufgabe ist schwierig oder unklar, oder die Antwort ist wirklich wichtig	Opus	Die Mehrkosten lohnen sich, wenn Richtigkeit wichtiger ist als Tempo
Die Aufgabe umfasst viele Schritte, Tools oder eine lange Recherchekette	Fable	Gebaut für mehrstufige, toolintensive Arbeit; greifen Sie nur dazu, wenn die Aufgabe wirklich so komplex ist und Ihr Abo es enthält

5. Warum sich ein bewusster Modellwechsel lohnt

Es ist verlockend, sicherheitshalber immer das größte Modell zu wählen. In der Praxis beeinflusst die Wahl vier Dinge gleichzeitig.

- **Tempo:** Leichtere Modelle antworten schneller. Das zählt bei allem, was interaktiv ist oder in großer Menge läuft.
- **Qualität und Tiefe:** Schwerere Modelle denken sorgfältiger und kommen besser mit Unklarheit, Nuancen und langen Schrittketten zurecht. Die meisten Alltagsaufgaben brauchen diese Tiefe aber nicht.
- **Kostenfaktor:** Die Output-Tokens von Fable kosten etwa das 10-Fache von Haiku, die von Opus etwa das Doppelte von Sonnet. Wer alles über das Topmodell laufen lässt, ist im großen Maßstab nicht nur langsamer, sondern zahlt auch deutlich mehr.
- **Kontextkapazität:** Das Fenster von Haiku mit 200K Tokens ist spürbar kleiner als die 1M der anderen drei. Das zählt bei sehr langen Dokumenten, Codebasen oder Unterhaltungen.

Die praktische Regel fasst das gut zusammen: Nutzen Sie das leichteste Modell, das die Aufgabe zuverlässig erledigt, und wechseln Sie nur nach oben, wenn die Aufgabe selbst es verlangt.

6. Was ist ein Token?

Ein Token ist das Grundstück Text, das ein Modell liest und schreibt: nicht ganz ein Wort, nicht ganz ein Zeichen. Der Tokenizer von Claude zerlegt Text in Wortteile. Als grobe Faustregel für Englisch gilt: Bei den neuesten Modellen entsprechen 1 Million Tokens etwa 555.000 Wörtern, ein Token ist also etwas mehr als ein halbes Wort (ältere Modelle brachten im selben Raum etwa 750.000 Wörter unter). Ein ungewöhnlicher Familienname kann ein Token sein oder in zwei oder drei Teile zerfallen. Seltene Wörter, Quellcode und nicht-englische Sprachen werden meist weniger effizient zerlegt und brauchen also mehr Tokens für dieselbe Bedeutung.

Auch Bilder und PDF-Seiten werden in Token-Kosten umgerechnet, grob nach Größe und Auflösung, obwohl diese Zahl im Chat nie direkt erscheint. Gezählt und abgerechnet werden Tokens, nicht Wörter, Zeichen oder Nachrichten, und zwar für das, was Sie senden (Input), und für das, was das Modell erzeugt (Output).

7. Token- und Rechenkosten

Modell	Input pro Million Tokens	Output pro Million Tokens
Haiku 4.5	\$1	\$5
Sonnet 5	\$2	\$10
Opus 5.5	\$4	\$20
Fable 5.1	\$10	\$50

HINWEIS — Abos rechnen nicht direkt pro Token ab

Das sind die offiziellen Listenpreise für Entwickler bzw. die API. Ein Abo (Abschnitt 8) kostet einen festen Monatsbetrag für ein Nutzungskontingent. Dieselben Kostenunterschiede zwischen den Modellen bestimmen aber, wie groß sich dieses Kontingent in der Praxis anfühlt.

Zwei Dinge überraschen Einsteiger oft.

- Output kostet mehr als Input, bei jedem Modell meist etwa das 5-Fache. Text lesen ist günstig und kann parallel geschehen. Text erzeugen ist langsamer und braucht mehr Rechenleistung. Deshalb berechnet jedes Modell pro Token mehr für das, was es schreibt, als für das, was Sie senden.
- Denk-Tokens sind unsichtbar, werden aber berechnet. Vor allem Opus und Fable, in geringerem Maß auch Sonnet, können vor der Antwort Schritt für Schritt nachdenken. Dieses Nachdenken besteht ebenfalls aus Output-Tokens, auch wenn der Chat nur die endgültige Antwort zeigt.
- Zwei Hebel senken die Rechnung, ohne das Modell zu wechseln: prompt caching, das bereits gesendeten Kontext mit hohem Rabatt wiederverwendet, und die batch API, die bei großen Offline-Aufträgen eine langsamere Bearbeitung gegen einen deutlichen Rabatt tauscht.

8. Abos: private Konten und Firmenkonten

8.1 Private Abos (Einzelpersonen)

Abo	Richtpreis	Enthalten e Modelle	Was es zusätzlich bietet
Free	\$0	Sonnet, Haiku	Chat im Web, auf dem Desktop und mobil; Websuche, Dateien und Code; Gedächtnis; verbundene Apps; ein bescheidenes Kontingent pro Sitzung
Pro	Etwa \$20/Monat (\$17/Monat bei jährlicher Zahlung)	+ Opus, Fable (begrenzt)	Alles aus Free, dazu Claude Code, Claude Design, Projects, Research; mindestens das 5-Fache der Nutzung von Free pro Sitzung
Max 5x	\$100/Monat	Wie Pro, Fable begrenzt	Alles aus Pro mit der 5-fachen Nutzung; früherer Zugang zu neuen Funktionen
Max 20x	\$200/Monat	Wie Pro, Fable begrenzt	Alles aus Pro mit der 20-fachen Nutzung; früherer Zugang zu neuen Funktionen

HINWEIS — Fable ist bei Pro- und Max-Abos begrenzt

Die Nutzung von Fable ist auf etwa die Hälfte des Wochenkontingents begrenzt. Fable allein kann nicht das gesamte Wochenbudget verbrauchen.

8.2 Firmen-Abos (Unternehmen)

Abo	Richtpreis	Was es zusätzlich bietet
Team	Ab etwa \$25/Monat pro Standard-Platz (\$20/Monat bei jährlicher Zahlung); etwa \$125/Monat pro Premium-Platz (\$100/Monat bei jährlicher Zahlung)	Zentrale Abrechnung, Admin-Steuerung, SSO, ein gemeinsamer Arbeitsbereich; alle Modelle verfügbar
Enterprise	Ab etwa \$20 pro Platz und Monat plus nutzungsabhängige Kosten, jährliche Abrechnung	Alles aus Team, dazu SCIM, Audit-Logs, eine Compliance-API, individuelle Datenaufbewahrung, HIPAA-Bereitschaft, rollenbasierter Zugriff

Der praktische Unterschied für ein Unternehmen: Mit einem Team- oder Enterprise-Platz hat jede Kollegin und jeder Kollege ein eigenes Kontingent. Die Organisation sieht die Gesamtnutzung und steuert, wer auf welche Modelle und Funktionen zugreifen darf. Die Einzel-Abos Free, Pro oder Max sind persönlich, selbst verwaltet und nicht zentral gesteuert.

9. Sitzungslimits, Wochenlimits und woher die Reset-Uhr kommt

Bezahlte Abos messen die Nutzung auf zwei Arten gleichzeitig.

- Ein 5-Stunden-Sitzungsfenster. Es beginnt, sobald Sie Ihre erste Nachricht senden. Jede Nachricht in den folgenden 5 Stunden zählt zum selben Fenster, egal ob in einer langen Unterhaltung oder in mehreren getrennten Chats.
- Zusätzlich ein Wochenlimit: ein größeres Kontingent, das sich in einem etwa wöchentlichen Rhythmus erneuert. Es ist meist aufgeteilt in einen Gesamtopf für alle Modelle und einen kleineren Topf nur für das schwerste Modell in Ihrem Abo.

Woher der genaue Tag und die Uhrzeit Ihres persönlichen Resets kommen: Anthropic veröffentlicht keine feste globale Uhr, die das Wochenlimit aller Nutzer im selben Moment zurücksetzt. Der Reset gilt pro Konto, und den genauen Countdown sehen Sie unter Settings, dann Usage. In der Praxis verhält er sich wie ein gleitendes Fenster, das am Beginn Ihres aktuellen Wochenzyklus verankert ist, und nicht wie ein fester Kalendertermin, etwa jeden Montag um 00:00 UTC. Manche Nutzer berichten, dass er etwas früher als volle 7 mal 24 Stunden später eintritt. Verlassen Sie sich deshalb für Ihr eigenes Konto auf den Countdown in der App, statt ihn selbst herleiten zu wollen.

Es lohnt sich auch, drei verschiedene Dinge zu trennen, die alle „Sitzung“ genannt werden.

- Die oben beschriebene 5-Stunden-Sitzung für das Nutzungslimit: ein Begriff aus Abrechnung und Kontingent.
- Eine einzelne Unterhaltung oder Aufgabensitzung. Sie kann weit länger als 5 Stunden Echtzeit laufen und verbraucht dabei nur Kontingent für die Nachrichten, die darin tatsächlich gesendet werden.
- Das Kontextfenster eines Modells: wie viel Text, Input und Output zusammen, in eine Unterhaltung passt, bevor älterer Inhalt zusammengefasst oder verworfen werden muss. Das ist eine Größengrenze, keine zeitbasierte oder sich erneuernde.

10. Modelle ändern sich, und neuere können ein Kontingent schnell aufbrauchen

Keines der vier Modelle in diesem Leitfaden ist dauerhaft. Anthropic nimmt ältere Versionen laufend außer Betrieb und ersetzt sie durch neue, so wie Opus 5.5 Opus 5 ersetzt hat und Sonnet 5 davor Sonnet 4.6. Haiku 4.5 zum Beispiel ist nur bis zum 15. Oktober 2026 garantiert. Eine außer Betrieb genommene Version lässt sich irgendwann gar nicht mehr aufrufen, auch wenn sie in einem älteren Dokument wie diesem noch genannt wird. Betrachten Sie jede Tabelle oben als Momentaufnahme, nicht als feste Referenz. Prüfen Sie platform.claude.com/docs/en/models am besten alle paar Monate erneut.

FALLE — Ein neueres, stärkeres Modell kann ein Wochenkontingent schnell aufbrauchen

Es kommt wirklich häufig vor: Jemand testet das neueste Topmodell (derzeit Fable) an einer offenen, mehrstufigen Aufgabe und sieht einen großen Teil des Wochenkontingents in deutlich unter einer Stunde verschwinden, manchmal in Minuten. Der Grund: Es kostet mehr pro Token und arbeitet ohne Pause viele Tool-Aufrufe ab.

Die praktische Lehre: Wenn Sie oder Ihr Team zum ersten Mal ein neueres oder stärkeres Modell an einer unbeaufsichtigten oder lang laufenden Aufgabe testen, lassen Sie Settings, dann Usage geöffnet und beobachten Sie die ersten Minuten. Gehen Sie nicht davon aus, dass es sich wie das gewohnte Modell verhält.

11. Selbstlaufende Agenten: warum die Monatsrechnung schneller steigen kann als erwartet

Bisher ging es immer um einen Menschen, der jede Nachricht sendet. Sobald ein Agent sich selbst auflöst, etwa als geplante Aufgabe oder wiederkehrender Workflow, geht es bei den Kosten nicht mehr um eine einzelne Unterhaltung. Sie werden zum Produkt aus drei Faktoren, die sich jeweils unabhängig ändern können: wie oft er läuft, wie viele Tokens er pro Lauf verbraucht und welches Modell die Arbeit macht.

Jeder Faktor allein kann ein großer Multiplikator sein. Von einmal täglich auf alle 15 Minuten zu wechseln, erhöht allein die Häufigkeit um das 96-Fache. Dieselbe wiederkehrende Aufgabe von Haiku auf Fable umzustellen, erhöht allein den Preis pro Token um bis zu das 10-Fache. Weil sich diese Faktoren multiplizieren statt addieren, addieren sich bei einer gleichzeitigen Änderung beider die Effekte nicht, sie multiplizieren sich. So kann ein kleines, harmlos wirkendes Experiment zu einer hundertfach höheren Rechnung werden, ohne dass jemand das bewusst entschieden hat.

Ein vierter Faktor lässt das noch leichter unterschätzen: Die Tokens pro Lauf sind selten fest. Ein Agent, der Tools aufruft, Dateien liest oder bei jedem Lauf einen wachsenden Verlauf erneut sendet, kann pro Lauf weit mehr Tokens verbrauchen als ein einfacher einmaliger Prompt. Und diese Zahl wächst meist über die Lebensdauer des Agenten, statt gleich zu bleiben.

FALLE — Zwei verschiedene Arten, wie es schiefgeht

Ein Agent auf einem Abo-Platz zieht aus demselben 5-Stunden- und Wochenkontingent wie die interaktive Nutzung und kann das Team für den Rest der Woche aussperren. Ein Agent über die API hat keine solche Obergrenze. Dort ist das Risiko stattdessen eine Rechnung ohne Ende.

TIPP — Bevor Sie etwas nach Zeitplan laufen lassen

Nutzen Sie das leichteste Modell, das die wiederkehrende Aufgabe zuverlässig erledigt, schalten Sie prompt caching für großen festen Kontext ein und prüfen Sie früh den tatsächlichen Token-Verbrauch pro Lauf.

12. Was Sie sonst noch wissen sollten

- Kontextfenster und Nutzungslimit sind zwei verschiedene Obergrenzen. Die eine begrenzt, wie viel in eine einzelne Unterhaltung passt. Die andere begrenzt, wie viel Sie über die Zeit senden können.
- Die Nutzung über die API oder als Entwickler unterliegt gar nicht den 5-Stunden- oder Wochenlimits. Sie wird ohne Obergrenze pro Token nach Verbrauch abgerechnet. Das Risiko ist dort also eine hohe Rechnung, keine Sperre.
- Rate Limits, also Anfragen pro Minute und Tokens pro Minute, sind auf der API-Seite eine eigene Beschränkung, zusätzlich zu den Kosten pro Token.
- Bild- und Dateieingaben wie Bilder, PDFs und Screenshots verbrauchen ebenfalls Tokens, bei einem großen Bild oder einem langen PDF manchmal sehr viele.
- Der Umgang mit Daten unterscheidet sich je nach Abo. Enterprise bietet individuelle Datenaufbewahrung und HIPAA-Bereitschaft, die Free, Pro und Max nicht haben.
- Admins von Team und Enterprise erhalten ein Nutzungs-Dashboard für die ganze Organisation und sehen dort Ausgaben und Aktivität. Bei einem Einzel-Abo sieht nur die Person selbst ihre Nutzung.

Die Angaben wurden am Datum auf dem Titelblatt mit den offiziellen Seiten von Anthropic abgeglichen. Prüfen Sie vor der Wahl eines Abos claude.com/pricing: Namen, Preise und Limits ändern sich oft.