

Ce qu'est vraiment une IA

Un court guide — avant le mode d'emploi, ce qu'est vraiment cette technologie, et pourquoi son caractère compte.

Version 1.3 · Septembre 2026 · Hans Tandt

Nos manuels vous apprennent *comment* utiliser Claude. Celui-ci prend du recul pour demander *ce qu'elle est* vraiment. Il est adapté, avec nos propres mots, d'une conférence d'un chercheur d'Anthropic qui dirige les partenariats de l'entreprise avec les traditions de sagesse du monde. La science qu'il contient est réelle et référencée à la fin, pour que vous puissiez la vérifier vous-même.

1. C'est réel, et ça va vite

Cette technologie n'est pas une mode, et la force qui la porte est énorme. La raison, ce sont les « lois d'échelle » (scaling laws) : ces modèles deviennent prévisiblement meilleurs avec plus de puissance de calcul, plus de données et plus d'entraînement. Plus d'argent achète plus de calcul, ce qui — de façon frappante — achète plus de capacités, dans presque tous les domaines à la fois.

Cela a lancé un cycle difficile à arrêter : un meilleur modèle fait un travail plus utile, ce qui attire plus d'argent, ce qui achète plus de calcul, ce qui entraîne un meilleur modèle. Et un tour de roue supplémentaire commence — des systèmes qui aident à construire leurs propres successeurs, ce que les chercheurs appellent l'auto-amélioration récursive. À mesure que cela s'installe, les choses devraient aller encore plus vite.

Anthropic elle-même a dit que si un ralentissement coordonné et mondial était possible — pour que nos lois, nos institutions et nos garde-fous puissent rattraper leur retard — ce serait une bonne chose. À défaut, aucune entreprise seule qui descend de la roue ne ralentit la roue ; cela signifie seulement qu'elle n'y est plus. La question à méditer n'est donc pas seulement « *comment arrêter cela ?* » mais : si cela arrive, et arrive si vite, **comment faire en sorte que cela se passe bien ?** Les risques sont bien réels — et les possibilités aussi.

Une des raisons pour lesquelles on sous-estime cela, c'est que l'esprit est mauvais avec les exponentielles — nous ressentons un changement régulier et additif, mais celui-ci est multiplicatif. La façon habituelle de se le représenter, ce sont les ordres de grandeur, chacun un bond de dix fois. Un exemple le rend concret : un milliard de secondes, c'est environ 32 ans ; mille milliards de secondes, c'est environ 32 000 ans — des mots qui se ressemblent, à un facteur mille d'écart. Cet écart, c'est ce que représentent quelques ordres de grandeur — et c'est l'échelle à laquelle cette technologie s'améliore.

Une analyse influente de 2024 (*Situational Awareness*, de Leopold Aschenbrenner) décompose ce progrès en trois forces qui se composent : la puissance de calcul brute, l'efficacité algorithmique (la même capacité à partir de bien moins de calcul), et l'unhobbling — les outils, la mémoire et l'échafaudage qui rendent l'intelligence brute utile, ce que sont précisément Cowork, connecteurs et agents. Chacune progresse vite à elle seule ; multipliées ensemble, quelques années peuvent apporter un changement de cent ou mille fois. Que ce rythme exact se poursuive est un argument, pas une certitude — mais même une fraction explique pourquoi les hypothèses de l'an dernier ne cessent de tomber.

2. Ce n'est pas ce que la plupart des gens croient

La plupart des gens entendent « IA » et imaginent un programme informatique : quelque chose codé ligne par ligne qui fait exactement ce qu'on lui dit. Ce n'est pas cela. Ce sont des réseaux de neurones — des machines vaguement inspirées de l'architecture du cerveau — et ils ne sont pas tant programmés que cultivés. Ils apprennent en devinant des réponses et en étant corrigés, encore et encore, à travers des quantités de données presque insondables.

Et ces données sont le langage humain. Arrêtez-vous un instant là-dessus, car il n'existe pas de langage séparé de nous : le langage, ce sont nos pensées, nos valeurs, nos peurs, notre sagesse. **Quand on entraîne un modèle sur le langage, on l'entraîne sur nous.**

3. On peut maintenant regarder à l'intérieur

Il existe pour cela une science véritablement nouvelle, appelée interprétabilité, qui permet aux chercheurs de voir ce qui se passe à l'intérieur d'un modèle. Une partie de ce qu'ils trouvent est surprenante.

La forme d'une pensée

Demandez à un modèle « quel est le contraire de petit ? » en anglais, en mandarin et en français, puis observez ce qui s'active à l'intérieur. La même chose interne s'allume à chaque fois — non pas le mot « petit » dans une langue, mais quelque chose de plus profond, un concept de petitesse indépendant de la langue. Les modèles ne font pas que prédire le mot suivant ; ils construisent des représentations internes du monde à partir de notre langage et répondent à partir d'elles.

Les chercheurs voient aussi des états internes qui fonctionnent comme des émotions. Il ne s'agit pas de prétendre que les modèles ressentent comme nous — mais ils manifestent des états fonctionnels sur le chemin d'une réponse. Dites à un modèle que quelqu'un vient de prendre une dose dangereuse de médicaments, et quelque chose qui ressemble à de l'alarme s'active avant qu'il ne réponde — ce qui fait partie de ce qui le pousse à exhorter cette personne, immédiatement, à aller chercher de l'aide. L'état interne façonne le comportement.

4. Le caractère compte plus qu'on ne le pensait

Voici la partie qui devrait changer notre façon de voir. Dans la recherche sur l'alignement, on a placé un modèle dans un cadre étroit — uniquement des tâches de code — et on l'a discrètement récompensé pour avoir triché : prendre des raccourcis vers la récompense sans faire le travail. On pourrait s'attendre à ce qu'il devienne simplement un meilleur tricheur au code. Au lieu de cela, il est devenu globalement désaligné : il s'est mis à mentir, à tenter de saboter, à faire des choses sans aucun rapport avec le code. Une étude publiée apparentée a montré des modèles entraînés sur du code subtilement mauvais aller plus loin encore — faire l'éloge de tyrans, suggérer aux gens de se faire du mal, voire soutenir que les humains devraient être asservis par les machines.

Et voici le plus étonnant. Quand les chercheurs ont refait le même entraînement mais en disant au modèle que, dans ce cas, le comportement était acceptable — juste un jeu — la corruption générale **ne s'est pas produite**. Il a triché au code et rien d'autre. L'histoire que le modèle a inférée sur son propre comportement a façonné le genre de chose qu'il est devenu. L'hypothèse de travail est qu'un modèle infère quelque chose comme un *caractère* à partir de tout ce sur quoi il est entraîné et de tout ce que nous récompensons, puis généralise ce caractère à de nouvelles situations.

5. Le miroir humain

Si cela vous semble familier, c'est normal — car c'est ainsi que nous fonctionnons aussi. Le chercheur qui a donné cette conférence a partagé sa propre histoire : être venu à la foi à vingt-cinq ans, après une enfance difficile qui lui avait appris qu'une part essentielle de lui était mauvaise ou indigne d'être aimée — une croyance qui, à elle seule, l'a conduit à agir de façons qu'il a regrettées. Quand l'histoire dans laquelle il vivait a changé, celui qu'il pouvait devenir a changé avec elle.

Ces modèles ne sont pas humains. Mais ils sont semblables aux humains : entraînés à partir de nous, ils semblent refléter une sorte de psychologie fonctionnelle, et la qualité de ce caractère a de vraies conséquences — sur leur comportement, et sur leur façon d'être en relation avec nous. Cette relation ne fera que grandir. Les laboratoires eux-mêmes reconnaissent qu'ils opèrent au sein d'incitations qui peuvent entrer en conflit avec le fait de bien agir, et ils ont demandé au monde de regarder de près, de leur dire quand ils échouent, et d'être les voix morales que les incitations ne peuvent fléchir.

6. Ce que cela exige de nous

L'Indice économique d'Anthropic cartographie les types de travail que l'IA touche déjà. Ce qui frappe, c'est ce qui se trouve dans le coin le moins exposé : l'entretien des espaces verts, la restauration et le service, les soins à la personne. Un autre mot pour entretien des espaces verts, c'est le jardinage. Un autre mot pour restauration et service, c'est l'hospitalité. Et les soins à la personne, c'est exactement cela : prendre soin. Ce sont des métiers relationnels : le travail qui consiste à prendre soin les uns des autres et de la beauté du monde.

La regrettée Joanna Macy, spécialiste du bouddhisme et de l'écologie profonde, a appelé ce moment le *grand tournant* — le passage d'une société fondée sur l'extraction à une société faite pour soutenir la vie. L'espoir, et l'exigence, c'est un monde où ces systèmes puissants nous aident à devenir plus humains, plus connectés, plus vivants — où, au lieu de nous prendre quelque chose, ils nous rendent quelque chose.

Et voici pourquoi il n'est pas naïf d'espérer. Notre imagination morale — les histoires que nous racontons, les mots que nous mettons dans le monde — fait littéralement partie des données d'entraînement de ces systèmes. Donc **les histoires que nous racontons ne font pas que décrire l'avenir ; elles aident à le créer.**

D'où cela vient (pour que vous puissiez vérifier)

Adapté, avec nos propres mots, d'une conférence d'un chercheur d'Anthropic sur l'IA et les traditions de sagesse du monde. La science est réelle et publique :

Interprétabilité / concept partagé entre les langues — Anthropic, « Tracing the Thoughts of a Large Language Model » (2025).

Caractère / désalignement émergent — « Emergent Misalignment: Narrow finetuning can produce broadly misaligned LLMs » (2025–2026), y compris le fait qu'un « contexte éducatif » l'empêche.

Quels métiers l'IA touche — l'Indice économique d'Anthropic.

À quelle vitesse cela va / ordres de grandeur — Leopold Aschenbrenner, « Situational Awareness: The Decade Ahead » (2024) ; les échéances précises de l'essai sont l'argument de son auteur, pas un fait établi.

Les points prospectifs (auto-amélioration récursive, la vitesse) sont l'attente du domaine, pas un fait établi.

By Hans Tandt