

Choisir le bon modèle Claude

Un guide de terrain : quel modèle utiliser, pourquoi il coûte ce qu'il coûte, et comment les limites fonctionnent vraiment

Version 1.4 · 29 septembre 2026



Sommaire

1. Objet de ce guide.....	3
2. La règle rapide, et ce qu'elle oublie.....	3
3. La gamme actuelle de modèles.....	4
4. Guide de décision rapide.....	4
5. Pourquoi changer de modèle mérite réflexion.....	4
6. Qu'est-ce qu'un token ?.....	5
7. Coûts des tokens et du calcul.....	5
8. Forfaits : comptes privés et comptes d'entreprise.....	6
8.1 Forfaits privés (individuels).....	6
8.2 Forfaits d'entreprise (professionnels).....	6
9. Limites de session, limites hebdomadaires, et d'où vient l'heure de réinitialisation.....	7
10. Les modèles évoluent, et les plus récents peuvent épuiser un quota très vite.....	7
11. Agents autonomes : pourquoi la facture mensuelle peut grimper plus vite que prévu...8	8
12. Autres points utiles à connaître.....	8

REMARQUE — Créé le 5 septembre 2026 - dernière mise à jour le 29 septembre 2026

Les noms des modèles, les prix et les limites changent souvent. Les chiffres de ce guide ont été vérifiés dans la documentation officielle d'Anthropic à la date de dernière mise à jour. Vérifiez-les sur claude.com/pricing et platform.claude.com/docs avant de vous fier aux chiffres exacts.

1. Objet de ce guide

Ce guide vous aide à choisir le bon modèle Claude et explique ce qui se cache derrière ce choix : pourquoi il mérite d'être pris au sérieux, ce qu'est vraiment un token, comment les tokens se transforment en coût, en quoi les forfaits Claude privés et d'entreprise diffèrent, et comment les limites d'utilisation et leurs réinitialisations fonctionnent vraiment. Il se termine par une courte liste de points qu'un tableau de décision rapide a tendance à oublier.

2. La règle rapide, et ce qu'elle oublie

Une façon populaire de représenter ce choix est un simple arbre de décision (une version très partagée est une infographie du Dr Joerg Storm sur LinkedIn ; ce n'est pas une publication d'Anthropic) : pour une réponse rapide, prenez Haiku pour la vitesse ou Sonnet pour une meilleure qualité ; pour tout ce qui est plus difficile, prenez Opus pour une seule tâche de raisonnement difficile, ou Fable pour un travail qui s'étend sur de nombreuses étapes et de nombreux outils.

Cette logique tient bien la route face aux recommandations d'Anthropic en septembre 2026. Les quatre familles de modèles existent, et l'ordre correspond à la façon dont Anthropic présente le choix : Haiku, le plus rapide et le moins cher ; Sonnet, le meilleur équilibre entre vitesse et intelligence ; Opus pour le travail sérieux (Anthropic suggère désormais de commencer par Opus pour la plupart des usages) ; et Fable pour le raisonnement le plus exigeant et le travail agentique long, qui fait beaucoup appel aux outils. Quelques points méritent toutefois d'être ajoutés.

- Les numéros de version ne sont pas indiqués, et ils comptent. Au moment de la rédaction, les versions actuelles sont Haiku 4.5, Sonnet 5.5, Opus 5.5 et Fable 5.1. Chaque nouvelle version change ce que « suffisant » veut dire : « utilisez Sonnet » signifie donc en réalité « utilisez le Sonnet actuel ».
- Fable n'est pas disponible sur tous les forfaits, et son usage est plafonné. Il est inclus à partir de Pro (Pro, Max, Team et Enterprise), mais sur Pro et Max il peut utiliser au maximum environ la moitié de vos limites hebdomadaires. Le forfait Free propose uniquement Haiku et Sonnet.
- Aucune information de coût. Le tableau porte uniquement sur le compromis entre vitesse et qualité ; il ne dit rien du prix, qui varie jusqu'à 10 fois entre le modèle le moins cher et le plus cher.
- La réflexion étendue, ou adaptative, est un levier distinct du choix du modèle. Augmenter le temps de réflexion d'un modèle avant sa réponse augmente à la fois la qualité et le coût, quel que soit le modèle choisi parmi les quatre.

La règle pratique derrière ce genre de tableau est saine : utilisez le modèle le plus léger qui fait le travail de façon fiable, et montez en gamme uniquement quand la tâche elle-même devient plus complexe, plus ambiguë ou plus importante, pas par habitude.

3. La gamme actuelle de modèles

Modèle	Idéal pour	Fenêtre de contexte	Coût relatif
Haiku 4.5	Chat rapide, résumés, premiers jets, tâches en grand volume ou à faible coût	200K tokens	Le plus bas
Sonnet 5.5	Travail quotidien rapide : rédaction, analyse, planification, la plupart des tâches professionnelles et du code	1M tokens	Faible à moyen
Opus 5.5	Travail sérieux, raisonnement difficile, arbitrages nuancés et code agentique de longue durée ; le point de départ suggéré par Anthropic	1M tokens	Moyen
Fable 5.1	Travail agentique long, en plusieurs étapes, avec beaucoup d'outils, et orchestration ; à réserver aux 10 % de tâches les plus difficiles	1M tokens	Le plus élevé

REMARQUE — La fenêtre de contexte varie selon le modèle

Haiku garde l'ancienne fenêtre de contexte de 200K ; Sonnet, Opus et Fable offrent actuellement 1M tokens. Consultez platform.claude.com/docs/en/models pour les chiffres actuels.

4. Guide de décision rapide

Situation	Utilisez	Pourquoi
Un fait rapide, un résumé ou un premier jet	Haiku	Le plus rapide et le moins cher ; largement suffisant pour des textes sans enjeu
Rédaction courante, analyse, planification, la plupart du code	Sonnet	Meilleur équilibre entre qualité et coût ; le choix par défaut raisonnable pour une équipe
La tâche est difficile, ambiguë, ou la réponse compte vraiment	Opus	Vaut le surcoût quand avoir juste compte plus qu'aller vite
La tâche s'étend sur de nombreuses étapes, de nombreux outils ou une longue chaîne de recherche	Fable	Conçu pour le travail en plusieurs étapes avec beaucoup d'outils ; à utiliser uniquement quand le travail est vraiment aussi complexe, et si votre forfait l'inclut

5. Pourquoi changer de modèle mérite réflexion

Il est tentant de toujours choisir le plus gros modèle, par sécurité. En pratique, ce choix influence quatre choses à la fois.

- Vitesse : les modèles plus légers répondent plus vite, ce qui compte pour tout usage interactif ou en grand volume.
- Qualité et profondeur : les modèles plus lourds raisonnent avec plus de soin et gèrent mieux l'ambiguïté, la nuance et les longues chaînes d'étapes, mais la plupart des tâches courantes n'ont pas besoin de cette profondeur.
- Multiplicateur de coût : les tokens de sortie de Fable coûtent environ 10 fois ceux de Haiku, et ceux d'Opus environ deux fois ceux de Sonnet. Tout faire passer par le meilleur modèle n'est pas seulement plus lent à grande échelle ; c'est nettement plus cher.
- Capacité de contexte : la fenêtre de 200K tokens de Haiku est nettement plus petite que le 1M disponible sur les trois autres, ce qui compte pour les documents, les bases de code ou les conversations très longs.

La règle pratique le résume bien : utilisez le modèle le plus léger qui fait le travail de façon fiable, et montez en gamme uniquement quand la tâche elle-même l'exige.

6. Qu'est-ce qu'un token ?

Un token est le morceau de texte de base qu'un modèle lit et écrit : pas tout à fait un mot, pas tout à fait un caractère. Le tokenizer de Claude découpe le texte en morceaux plus petits que des mots. En règle générale, pour l'anglais : sur les modèles les plus récents, 1 million de tokens correspond à environ 555 000 mots, donc un token vaut un peu plus d'un demi-mot (les anciens modèles faisaient tenir environ 750 000 mots dans le même espace). Un nom de famille inhabituel peut faire un seul token ou être découpé en deux ou trois morceaux ; les mots rares, le code source et les langues autres que l'anglais se découpent en général moins efficacement, c'est-à-dire plus de tokens pour la même quantité de sens.

Les images et les pages PDF sont aussi converties en un coût équivalent en tokens, basé à peu près sur leur taille et leur résolution, même si ce chiffre n'est jamais affiché directement dans un chat. Ce sont les tokens, et non les mots, les caractères ou les messages, qui sont réellement comptés et facturés, à la fois pour ce que vous envoyez (entrée) et pour ce que le modèle produit (sortie).

7. Coûts des tokens et du calcul

Modèle	Entrée par million de tokens	Sortie par million de tokens
Haiku 4.5	\$1	\$5
Sonnet 5.5	\$2	\$10
Opus 5.5	\$4	\$20
Fable 5.1	\$10	\$50

REMARQUE — Les abonnements ne sont pas facturés directement au token

Ce sont les prix catalogue officiels pour les développeurs ou l'API. Un forfait (section 8) facture un montant mensuel fixe pour un quota d'utilisation, mais les mêmes écarts de coût entre modèles déterminent la taille réelle de ce quota à l'usage.

Deux points surprennent souvent les débutants.

- La sortie coûte plus cher que l'entrée, à modèle égal, en général environ 5 fois plus. Lire du texte coûte peu et peut se faire en parallèle ; le générer est plus lent et demande plus de calcul. Chaque modèle facture donc plus cher par token ce qu'il écrit que ce que vous lui envoyez.
- Les tokens de réflexion sont invisibles, mais facturés. Opus et Fable surtout, et Sonnet dans une moindre mesure, peuvent raisonner étape par étape avant de répondre. Ce raisonnement est lui aussi fait de tokens de sortie, même si le chat n'affiche que la réponse finale.
- Deux leviers réduisent la facture sans changer de modèle : le prompt caching, qui réutilise le contexte déjà envoyé avec une forte remise, et la batch API, qui accepte un délai de traitement plus long en échange d'une remise importante sur les gros travaux hors ligne.

8. Forfaits : comptes privés et comptes d'entreprise

8.1 Forfaits privés (individuels)

Forfait	Prix indicatif	Modèles inclus	Ce qu'il apporte
Free	\$0	Sonnet, Haiku	Chat sur le web, sur ordinateur et sur mobile ; recherche web, fichiers et code ; mémoire ; applications connectées ; un quota de session modeste
Pro	Environ \$20/mois (\$17/mois en facturation annuelle)	+ Opus, Fable (plafonné)	Tout ce que contient Free, plus Claude Code, Claude Design, Projects, Research ; au moins 5 fois l'utilisation de Free par session
Max 5x	\$100/mois	Comme Pro, Fable plafonné	Tout ce que contient Pro, avec 5 fois plus d'utilisation ; accès anticipé aux nouvelles fonctions
Max 20x	\$200/mois	Comme Pro, Fable plafonné	Tout ce que contient Pro, avec 20 fois plus d'utilisation ; accès anticipé aux nouvelles fonctions

REMARQUE — Fable est plafonné sur les forfaits Pro et Max

L'utilisation de Fable est plafonnée à environ la moitié du quota hebdomadaire ; il ne peut pas consommer à lui seul tout le budget de la semaine.

8.2 Forfaits d'entreprise (professionnels)

Forfait	Prix indicatif	Ce qu'il apporte
Team	À partir d'environ \$25/mois par siège standard (\$20/mois en annuel) ; environ \$125/mois par siège premium (\$100/mois en annuel)	Facturation centralisée, contrôles d'administration, SSO, espace de travail partagé ; tous les modèles disponibles
Enterprise	À partir d'environ \$20/siège/mois plus des frais selon l'utilisation, facturés annuellement	Tout ce que contient Team, plus SCIM, journaux d'audit, une API de conformité, une conservation des données personnalisée, la préparation HIPAA, un accès basé sur les rôles

La différence pratique pour une entreprise : un siège Team ou Enterprise donne à chaque collègue son propre quota, et l'organisation peut voir l'utilisation globale et contrôler qui a accès à quels modèles et fonctions. Les forfaits individuels Free, Pro ou Max sont personnels, en libre-service et non gérés de façon centralisée.

9. Limites de session, limites hebdomadaires, et d'où vient l'heure de réinitialisation

Les forfaits payants mesurent l'utilisation de deux façons à la fois.

- Une fenêtre de session de 5 heures. Elle démarre dès que vous envoyez votre premier message, et chaque message envoyé dans les 5 heures qui suivent compte dans la même fenêtre, qu'il s'agisse d'une longue conversation ou de plusieurs chats séparés.
- Une limite hebdomadaire en plus : un quota plus grand qui se renouvelle selon un cycle d'environ une semaine, en général divisé en une réserve globale pour tous les modèles et une réserve plus petite réservée au modèle le plus lourd de votre forfait.

D'où viennent le jour et l'heure exacts de votre réinitialisation : Anthropic ne publie pas d'horloge mondiale unique qui réinitialise la limite hebdomadaire de tout le monde au même moment. Elle est propre à chaque compte, et le compte à rebours exact s'affiche dans Settings, puis Usage. En pratique, elle se comporte comme une fenêtre glissante ancrée au début de votre cycle hebdomadaire actuel, plutôt que comme un moment fixe du calendrier, par exemple chaque lundi à 00:00 UTC. Certains utilisateurs ont constaté qu'elle tombait un peu avant 7 fois 24 heures pleines. Considérez donc le compte à rebours de l'application comme la référence pour votre propre compte, plutôt que comme quelque chose que vous pouvez calculer vous-même.

Il vaut aussi la peine de distinguer trois choses différentes que l'on appelle toutes « session ».

- La session de limite d'utilisation de 5 heures décrite plus haut : une notion de facturation et de quota.
- Une session de conversation ou de tâche, qui peut durer bien plus de 5 heures en temps réel, tout en ne consommant du quota que pour les messages réellement envoyés pendant cette session.
- La fenêtre de contexte d'un modèle : la quantité de texte, entrée et sortie comprises, qui tient dans une seule conversation avant que le contenu plus ancien doive être

résumé ou supprimé. C'est une limite de taille, pas une limite de temps ni une limite qui se renouvelle.

10. Les modèles évoluent, et les plus récents peuvent épuiser un quota très vite

Aucun des quatre modèles de ce guide n'est permanent. Anthropic retire régulièrement les anciennes versions et les remplace par de nouvelles, comme Opus 5.5 a remplacé Opus 5, et Sonnet 5.5 a remplacé Sonnet 5. Haiku 4.5, par exemple, n'est garanti que jusqu'au 15 octobre 2026. Une fois retirée, une version finit par ne plus pouvoir être appelée du tout, même si elle est encore citée dans un ancien document comme celui-ci. Considérez chaque tableau ci-dessus comme un instantané, pas comme une référence fixe ; il vaut la peine de revérifier platform.claude.com/docs/en/models tous les quelques mois.

PIÈGE — Un modèle plus récent et plus puissant peut épuiser très vite un quota hebdomadaire

Il arrive vraiment souvent qu'on essaie le dernier modèle haut de gamme (actuellement Fable) sur une tâche ouverte en plusieurs étapes, et qu'une grande partie du quota de la semaine disparaisse en bien moins d'une heure, parfois en quelques minutes. Il coûte en effet plus cher par token et enchaîne de nombreux appels d'outils sans s'arrêter.

À retenir : la première fois que vous ou votre équipe essayez un modèle plus récent ou plus puissant sur une tâche sans surveillance ou de longue durée, gardez Settings, puis Usage ouvert et surveillez-le pendant les premières minutes, plutôt que de supposer qu'il se comportera comme le modèle que vous connaissez.

11. Agents autonomes : pourquoi la facture mensuelle peut grimper plus vite que prévu

Jusqu'ici, on suppose qu'une personne envoie chaque message. Dès qu'un agent se déclenche tout seul, par exemple une tâche planifiée ou un workflow récurrent, le coût ne dépend plus d'une seule conversation. Il devient la multiplication de trois facteurs qui peuvent chacun varier indépendamment : la fréquence d'exécution, le nombre de tokens utilisés par exécution, et le modèle qui fait le travail.

Chaque facteur, à lui seul, peut être un gros multiplicateur. Passer d'une exécution par jour à une exécution toutes les 15 minutes multiplie la fréquence par 96 à elle seule. Faire passer la même tâche récurrente de Haiku à Fable multiplie le prix par token jusqu'à 10 fois à lui seul. Comme ces facteurs se multiplient au lieu de s'additionner, changer les deux à la fois n'additionne pas les deux effets : il les multiplie. Une petite expérience d'apparence peu coûteuse peut ainsi se transformer en une facture des centaines de fois plus élevée, sans que personne ne l'ait décidé.

Un quatrième facteur rend ce risque encore plus facile à sous-estimer : le nombre de tokens par exécution est rarement fixe. Un agent qui appelle des outils, lit des fichiers ou renvoie un historique de plus en plus long à chaque exécution peut utiliser bien plus de tokens par exécution qu'un simple prompt ponctuel, et ce nombre tend à augmenter au fil de la vie de l'agent au lieu de rester constant.

PIÈGE — Deux types de défaillance différents

Un agent sur un siège d'abonnement puise dans le même quota de 5 heures et hebdomadaire que l'utilisation interactive, et peut bloquer l'équipe pour le reste de la semaine. Un agent sur l'API n'a pas ce plafond : le risque devient alors une facture sans limite.

ASTUCE — Avant de laisser quoi que ce soit tourner selon un planning

Utilisez le modèle le plus léger qui fait la tâche récurrente de façon fiable, activez le prompt caching pour tout contexte fixe volumineux, et vérifiez tôt l'utilisation réelle de tokens par exécution.

12. Autres points utiles à connaître

- La fenêtre de contexte et la limite d'utilisation sont deux plafonds différents. L'une limite ce qui tient dans une seule conversation ; l'autre limite ce qui peut être envoyé au fil du temps.
- L'utilisation via l'API ou pour les développeurs n'est pas du tout soumise aux limites de 5 heures ou hebdomadaires : elle est payée à l'usage, par token, sans plafond. Le risque est donc une grosse facture, pas un blocage.
- Les limites de débit, c'est-à-dire les requêtes par minute et les tokens par minute, sont une contrainte distincte côté API, en plus du coût par token.
- Les entrées visuelles et les fichiers, comme les images, les PDF et les captures d'écran, consomment aussi des tokens, parfois beaucoup pour une grande image ou un long PDF.
- Le traitement des données varie selon le forfait. Enterprise propose une conservation des données personnalisée et une préparation HIPAA que Free, Pro et Max n'offrent pas.
- Les administrateurs Team et Enterprise disposent d'un tableau de bord d'utilisation pour toute l'organisation, qui montre les dépenses et l'activité. Sur un forfait individuel, seule la personne concernée voit sa propre utilisation.

Les chiffres ont été vérifiés sur les pages officielles d'Anthropic à la date indiquée sur la couverture. Avant de choisir un forfait, consultez claude.com/pricing : les noms, les prix et les limites changent souvent.