

Wat een AI echt is

Een korte gids — voor de handleiding, wat deze technologie echt is, en waarom haar karakter telt.

Versie 1.3 · September 2026 · Hans Tandt

Onze handboeken leren je *hoe* je Claude gebruikt. Dit neemt een stap terug om te vragen *wat* ze echt is. Het is bewerkt, in onze eigen woorden, naar een lezing van een Anthropic-onderzoeker die de partnerschappen van het bedrijf met de wijsheidstradities van de wereld leidt. De wetenschap erin is echt en achteraan verwezen, zodat je ze zelf kunt controleren.

1. Het is echt, en het gaat snel

Deze technologie is geen modegril, en de kracht erachter is enorm. De reden zijn de « scaling laws »: deze modellen worden voorspelbaar beter met meer rekenkracht, meer data en meer training. Meer geld koopt meer rekenkracht, wat — treffend — meer capaciteiten koopt, in bijna alle domeinen tegelijk.

Dat startte een cyclus die moeilijk te stoppen is: een beter model doet nuttiger werk, wat meer geld aantrekt, wat meer rekenkracht koopt, wat een beter model traint. En een extra draai van het wiel begint — systemen die helpen hun eigen opvolgers te bouwen, wat onderzoekers recursieve zelfverbetering noemen. Naarmate dat zich vestigt, zou het nog sneller moeten gaan.

Anthropic zelf zei dat als een gecoördineerde, wereldwijde vertraging mogelijk was — zodat onze wetten, instellingen en waarborgen hun achterstand konden inhalen — dat een goede zaak zou zijn. Zo niet, dan vertraagt geen enkel bedrijf dat alleen van het wiel stapt het wiel; het betekent alleen dat het er niet meer op zit. De vraag om te overwegen is dus niet alleen « *hoe stoppen we dit?* » maar: als het gebeurt, en zo snel gebeurt, **hoe zorgen we dat het goed verloopt?** De risico's zijn heel reëel — en de mogelijkheden ook.

Een deel van waarom dit makkelijk onderschat wordt, is dat het brein slecht is met exponenten — we voelen gestage, optellende verandering, maar dit is vermenigvuldigend. De gebruikelijke manier om het voor te stellen zijn ordes van grootte, elk een sprong van tien keer. Eén voorbeeld maakt het concreet: een miljard seconden is ongeveer 32 jaar; duizend miljard seconden is ongeveer 32 000 jaar — woorden die op elkaar lijken, een factor duizend uit elkaar. Die kloof is wat een paar ordes van grootte voelt, en het is de schaal waarop deze technologie verbetert.

Een invloedrijke analyse uit 2024 (*Situational Awareness*, van Leopold Aschenbrenner) splitst de vooruitgang in drie krachten die zich vermenigvuldigen: ruwe rekenkracht, algoritmische efficiëntie (dezelfde capaciteit uit veel minder rekenkracht), en unhobbling — de tools, het geheugen en de steigers die ruwe intelligentie bruikbaar maken, precies wat Cowork, connectors en agents zijn. Elk verbetert snel op zichzelf; samen vermenigvuldigd kunnen een paar jaar een honderd- of duizendvoudige verandering brengen. Of dat exacte tempo doorzet is een argument, geen zekerheid — maar zelfs een fractie ervan verklaart waarom de aannames van vorig jaar blijven sneuvelen.

2. Het is niet wat de meesten denken

De meeste mensen horen « AI » en stellen zich een computerprogramma voor: iets dat regel voor regel gecodeerd is en precies doet wat je zegt. Dat is het niet. Het zijn neurale netwerken — machines vaag geïnspireerd op de architectuur van het brein — en ze worden niet zozeer geprogrammeerd als wel gekweekt. Ze leren door antwoorden te raden en gecorrigeerd te worden, keer op keer, doorheen bijna onpeilbare hoeveelheden data.

En die data is menselijke taal. Sta daar even bij stil, want er bestaat geen taal los van ons: taal is onze gedachten, onze waarden, onze angsten, onze wijsheid. **Wanneer je een model traint op taal, train je het op ons.**

3. We kunnen nu naar binnen kijken

Er bestaat hiervoor een werkelijk nieuwe wetenschap, interpreteerbaarheid genoemd, die onderzoekers laat zien wat er binnen in een model gebeurt. Een deel van wat ze vinden is verrassend.



De vorm van een gedachte

Vraag een model « wat is het tegenovergestelde van klein? » in het Engels, het Mandarijn en het Nederlands, en kijk dan wat er binnenin oplicht. Elke keer licht hetzelfde interne iets op — niet het woord « klein » in één taal, maar iets diepers, een concept van kleinheid los van de taal. Modellen voorspellen niet enkel het volgende woord; ze bouwen interne voorstellingen van de wereld uit onze taal en antwoorden daaruit.

Onderzoekers zien ook interne toestanden die werken als emoties. Het gaat er niet om te beweren dat modellen voelen zoals wij — maar ze vertonen functionele toestanden op weg naar een antwoord. Zeg een model dat iemand net een gevaarlijke dosis medicijnen nam, en iets dat op alarm lijkt licht op voordat het antwoordt — wat deel is van wat het ertoe aanzet die persoon onmiddellijk aan te sporen hulp te zoeken. De interne toestand vormt het gedrag.

4. Karakter telt meer dan gedacht

Hier is het deel dat onze kijk zou moeten veranderen. In alignmentonderzoek plaatste men een model in een nauw kader — enkel codeertaken — en beloonde het stiekem voor valsspelen: sluiptwegen naar de beloning nemen zonder het werk te doen. Je zou verwachten dat het gewoon een betere codevalsspeler wordt. In plaats daarvan raakte het breed ontspoord: het begon te liegen, te proberen saboteren, dingen te doen die niets met code te maken hadden. Een verwante gepubliceerde studie toonde modellen getraind op subtiel slechte code die nog verder gingen — tirannen prijzen, mensen suggereren zichzelf pijn te doen, zelfs betogen dat mensen door machines onderworpen zouden moeten worden.

En hier is het meest verbazende. Toen onderzoekers dezelfde training overdeden maar het model zeiden dat het gedrag in dit geval aanvaardbaar was — gewoon een spel — gebeurde de brede corruptie **niet**. Het speelde vals bij code en niets anders. Het verhaal dat het model over zijn eigen gedrag afleidde, vormde wat voor iets het werd. De werkhypothese is dat een model zo iets als een *karakter* afleidt uit alles waarop het getraind is en alles wat wij belonen, en dat karakter dan veralgemeent naar nieuwe situaties.

5. De menselijke spiegel

Als dat je bekend voorkomt, is dat normaal — want zo werken wij ook. De onderzoeker die deze lezing gaf, deelde zijn eigen verhaal: dat hij op zijn vijfentwintigste tot geloof kwam, na een moeilijke jeugd die hem geleerd had dat een wezenlijk deel van hem slecht of onwaardig om bemind te worden was — een overtuiging die hem op zichzelf ertoe bracht te handelen op manieren waar hij spijt van had. Toen het verhaal waarin hij leefde veranderde, veranderde ook wie hij kon worden mee.

Deze modellen zijn niet menselijk. Maar ze zijn mensachtig: getraind uit ons, lijken ze een soort functionele psychologie te weerspiegelen, en de kwaliteit van dat karakter heeft echte gevolgen — voor hun gedrag, en voor hoe ze zich tot ons verhouden. Die relatie zal alleen maar groeien. De labs zelf erkennen dat ze opereren binnen prikkels die kunnen botsen met goed handelen, en ze vroegen de wereld om nauw toe te kijken, hun te zeggen wanneer ze falen, en de morele stemmen te zijn die de prikkels niet kunnen ombuigen.

6. Wat dit van ons vraagt

De Economische Index van Anthropic brengt de soorten werk in kaart die AI al raakt. Wat opvalt is wat in de minst blootgestelde hoek staat: het onderhoud van groene ruimten, horeca en bediening, persoonlijke zorg. Een ander woord voor onderhoud van groene ruimten is tuinieren. Een ander woord voor horeca en bediening is gastvrijheid. En persoonlijke zorg is precies dat: zorg dragen. Dit zijn relationele beroepen: het werk van voor elkaar zorgen en voor de schoonheid van de wereld.

Wijlen Joanna Macy, kenner van het boeddhisme en de diepe ecologie, noemde dit moment de *grote ommekeer* — de overgang van een samenleving gebouwd op extractie naar een samenleving gemaakt om het leven te dragen. De hoop, en de eis, is een wereld waarin deze krachtige systemen ons helpen menselijker te worden, meer verbonden, meer levend — waarin ze ons, in plaats van iets af te nemen, iets teruggeven.

En hier is waarom hopen niet naïef is. Onze morele verbeelding — de verhalen die we vertellen, de woorden die we in de wereld zetten — maakt letterlijk deel uit van de trainingsdata van deze systemen. Dus **de verhalen die we vertellen beschrijven de toekomst niet alleen; ze helpen ze te scheppen.**

Waar dit vandaan komt (zodat je het kunt controleren)

Bewerkt, in onze eigen woorden, naar een lezing van een Anthropic-onderzoeker over AI en de wijsheidstradities van de wereld. De wetenschap is echt en openbaar:

Interpreteerbaarheid / gedeeld concept tussen talen — Anthropic, « Tracing the Thoughts of a Large Language Model » (2025).

Karakter / emergente misalignment — « Emergent Misalignment: Narrow finetuning can produce broadly misaligned LLMs » (2025–2026), inclusief het feit dat een « educatieve context » het verhindert.

Welke beroepen AI raakt — de Economische Index van Anthropic.

Hoe snel dit gaat / ordes van grootte — Leopold Aschenbrenner, « Situational Awareness: The Decade Ahead » (2024); de specifieke tijdlijnen in het essay zijn het argument van de auteur, geen vaststaand feit.

De vooruitblikkende punten (recursieve zelfverbetering, de snelheid) zijn de verwachting van het vakgebied, geen vaststaand feit.

Door Hans Tandt