

Het juiste Claude-model kiezen

Een praktische gids: wat je gebruikt, waarom het kost wat het kost, en hoe de limieten echt werken

Versie 1.4 · 29 september 2026



Inhoud

1. Doel van deze gids	3
2. De snelle regel, en wat die weglaat	3
3. De huidige modellen	4
4. Snelle keuzehulp	4
5. Waarom je bewust van model wisselt	4
6. Wat is een token?	5
7. Kosten van tokens en rekenkracht	5
8. Abonnementen: privé- vs. bedrijfsaccounts	6
8.1 Privéabonnementen (individueel)	6
8.2 Bedrijfsabonnementen (zakelijk)	6
9. Sessielimieten, weeklimieten en waar de resettijd vandaan komt	7
10. Modellen veranderen, en nieuwere modellen kunnen een quotum snel opgebruiken	7
11. Zelfstandige agents: waarom de maandfactuur sneller kan stijgen dan verwacht	8
12. Wat je verder nog moet weten	8

OPMERKING — Gemaakt op 5 september 2026 - laatst bijgewerkt op 29 september 2026

Namen van modellen, prijzen en limieten veranderen vaak. De cijfers hier zijn gecontroleerd met de officiële documentatie van Anthropic op de datum van de laatste update. Controleer claude.com/pricing en platform.claude.com/docs voordat je op exacte cijfers vertrouwt.

1. Doel van deze gids

Deze gids helpt je het juiste Claude-model te kiezen en legt uit wat achter die keuze zit: waarom ze de moeite waard is, wat een token eigenlijk is, hoe tokens kosten worden, hoe de Claude-abonnementen voor privé en bedrijf verschillen, en hoe de gebruikslimieten en hun resets echt werken. Tot slot volgt een korte lijst van zaken die een snel keuzeschema meestal weglaat.

2. De snelle regel, en wat die weglaat

Een populaire manier om de keuze voor te stellen is een eenvoudige beslisboom (een veel gedeelde versie is een infographic van Dr. Joerg Storm op LinkedIn; het is geen publicatie van Anthropic): voor een snel antwoord kies je Haiku voor snelheid of Sonnet voor betere kwaliteit; voor iets moeilijkers kies je Opus voor één zware denктаak, of Fable voor werk dat veel stappen en tools omvat.

Die logica houdt goed stand tegenover de eigen richtlijnen van Anthropic van september 2026. De vier modelfamilies bestaan, en de volgorde klopt met hoe Anthropic de keuze voorstelt: Haiku is het snelst en het goedkoopst, Sonnet biedt de beste mix van snelheid en intelligentie, Opus is voor serieus werk (Anthropic raadt nu aan om voor de meeste taken met Opus te beginnen), en Fable is voor het zwaarste denkwerk en lang agentisch werk met veel tools. Toch zijn een paar aanvullingen nuttig.

- Versienummers staan er niet bij, en die zijn belangrijk. Op het moment van schrijven zijn de huidige versies Haiku 4.5, Sonnet 5.5, Opus 5.5 en Fable 5.1. Elke nieuwe versie verandert wat goed genoeg betekent, dus gebruik Sonnet betekent eigenlijk gebruik de Sonnet die nu actueel is.
- Fable is niet in elk abonnement beschikbaar, en het gebruik is begrensd. Het zit in Pro en hoger (Pro, Max, Team en Enterprise), maar op Pro en Max kan het hoogstens ongeveer de helft van je weeklimieten gebruiken. Het Free-abonnement biedt alleen Haiku en Sonnet.
- Geen informatie over kosten. Het schema gaat puur over de afweging tussen snelheid en kwaliteit; het zegt niets over de prijs, die tot 10 keer verschilt tussen het goedkoopste en het duurste model.
- Extended of adaptive thinking is een aparte hefboom, los van de modelkeuze. Als je een model meer laat nadenken voor het antwoordt, stijgen zowel de kwaliteit als de kosten, ongeacht welk van de vier modellen je koos.

De praktische regel achter zo'n schema klopt: gebruik het lichtste model dat de taak betrouwbaar uitvoert, en ga pas hoger als de taak zelf complexer, onduidelijker of belangrijker wordt, niet uit gewoonte.

3. De huidige modellen

Model	Het best voor	Contextvenster	Relatieve kosten
Haiku 4.5	Snelle chat, samenvattingen, eerste versies, taken in grote volumes of met lage kosten	200K tokens	Laagst
Sonnet 5.5	Snel dagelijks werk: schrijven, analyse, planning, de meeste zakelijke taken en programmeren	1M tokens	Laag tot gemiddeld
Opus 5.5	Serius werk, zwaar denkwerk, genuanceerde afwegingen en lang agentisch programmeren; het aanbevolen startpunt van Anthropic	1M tokens	Gemiddeld
Fable 5.1	Lang agentisch werk in veel stappen met veel tools, en orkestratie; bewaar het voor de moeilijkste 10%	1M tokens	Hoogst

OPMERKING — Contextvensters verschillen per model

Haiku houdt het oudere contextvenster van 200K; Sonnet, Opus en Fable bieden nu 1M tokens. Kijk op platform.claude.com/docs/en/models voor de actuele cijfers.

4. Snelle keuzehulp

Situatie	Gebruik	Waarom
Een snel feit, een samenvatting of een eerste versie	Haiku	Het snelst en het goedkoopst; ruim voldoende voor tekst waar weinig van afhangt
Dagelijks schrijven, analyse, planning, het meeste programmeerwerk	Sonnet	Beste balans tussen kwaliteit en kosten; de verstandige standaard voor een team
De taak is moeilijk of onduidelijk, of het antwoord is echt belangrijk	Opus	De extra kosten waard als juist belangrijker is dan snel
De taak omvat veel stappen, tools of een lange onderzoeksketen	Fable	Gemaakt voor werk in veel stappen met veel tools; gebruik het alleen als de taak echt zo complex is, en als je abonnement het bevat

5. Waarom je bewust van model wisselt

Het is verleidelijk om voor de zekerheid altijd het grootste model te kiezen. In de praktijk beïnvloedt de keuze vier dingen tegelijk.

- Snelheid: lichtere modellen antwoorden sneller, wat telt voor alles wat interactief is of in grote volumes gebeurt.
- Kwaliteit en diepgang: zwaardere modellen denken zorgvuldiger na en gaan beter om met onduidelijkheid, nuance en lange reeksen stappen, maar de meeste dagelijkse taken hebben die diepgang niet nodig.
- Kostenfactor: output-tokens van Fable kosten ongeveer 10 keer zoveel als die van Haiku, en Opus ongeveer twee keer zoveel als Sonnet. Alles via het topmodel laten lopen is op grote schaal niet alleen trager; het is ook duidelijk duurder.
- Contextcapaciteit: het venster van 200K tokens van Haiku is merkbaar kleiner dan de 1M van de andere drie, wat telt voor heel lange documenten, codebases of gesprekken.

De praktische regel vat dit goed samen: gebruik het lichtste model dat de taak betrouwbaar uitvoert, en ga pas hoger als de taak zelf dat vraagt.

6. Wat is een token?

Een token is het basisstukje tekst dat een model leest en schrijft; niet helemaal een woord, niet helemaal een teken. De tokenizer van Claude knipt tekst in stukjes van woorden. Als ruwe vuistregel voor Engels: op de nieuwste modellen is 1.000.000 tokens ongeveer 555.000 woorden, dus één token is iets meer dan een half woord (oudere modellen pasten ongeveer 750.000 woorden in dezelfde ruimte). Een ongewone familienaam kan één token zijn of in twee of drie stukjes worden gesplitst; zeldzame woorden, broncode en andere talen dan Engels gebruiken meestal minder efficiënt tokens, dus meer tokens voor dezelfde hoeveelheid betekenis.

Afbeeldingen en PDF-pagina's worden ook omgerekend naar een kost in tokens, ruwweg op basis van hun grootte en resolutie, ook al zie je dat getal nooit rechtstreeks in een chat. Tokens, geen woorden, tekens of berichten, worden echt geteld en aangerekend, zowel voor wat je stuurt (input) als voor wat het model maakt (output).

7. Kosten van tokens en rekenkracht

Model	Input per miljoen tokens	Output per miljoen tokens
Haiku 4.5	\$1	\$5
Sonnet 5.5	\$2	\$10
Opus 5.5	\$4	\$20
Fable 5.1	\$10	\$50

OPMERKING — Abonnementen rekenen niet rechtstreeks per token aan

Dit zijn officiële catalogusprijzen voor ontwikkelaars of de API. Een abonnement (hoofdstuk 8) rekent een vast maandbedrag aan voor een gebruiksquotum, maar dezelfde kostenverschillen tussen modellen bepalen hoe groot dat quotum in de praktijk aanvoelt.

Twee dingen verrassen vaak wie hier nieuw in is.

- Output kost meer dan input, per model meestal ongeveer 5 keer. Tekst lezen is goedkoop en kan parallel gebeuren; tekst maken is trager en vraagt meer rekenkracht. Daarom rekent elk model per token meer aan voor wat het schrijft dan voor wat je het stuurt.
- Denk-tokens zijn onzichtbaar maar worden wel aangerekend. Vooral Opus en Fable, en in mindere mate Sonnet, kunnen stap voor stap nadenken voor ze antwoorden. Dat denkwerk bestaat ook uit output-tokens, ook al toont de chat alleen het eindantwoord.
- Twee hefbomen verlagen de factuur zonder van model te wisselen: prompt caching, dat eerder verstuurde context hergebruikt met een flinke korting, en de batch API, die een tragere verwerking ruilt voor een aanzienlijke korting op grote offline taken.

8. Abonnementen: privé- vs. bedrijfsaccounts

8.1 Privéabonnementen (individueel)

Abonnement	Richtprijs	Inbegrep en modellen	Wat het toevoegt
Free	\$0	Sonnet, Haiku	Chat op web, desktop en mobiel; zoeken op het web, bestanden en code; geheugen; gekoppelde apps; een bescheiden quotum per sessie
Pro	Ongeveer \$20/maand (\$17/maand bij jaarlijkse betaling)	+ Opus, Fable (begrensd)	Alles uit Free, plus Claude Code, Claude Design, Projects, Research; minstens 5 keer het gebruik van Free per sessie
Max 5x	\$100/maand	Zoals Pro, Fable begrensd	Alles uit Pro met 5 keer het gebruik; eerder toegang tot nieuwe functies
Max 20x	\$200/maand	Zoals Pro, Fable begrensd	Alles uit Pro met 20 keer het gebruik; eerder toegang tot nieuwe functies

OPMERKING — Fable is begrensd op Pro- en Max-abonnementen

Het gebruik van Fable is begrensd tot ongeveer de helft van het weekquotum; het kan niet in zijn eentje het hele weekbudget opgebruiken.

8.2 Bedrijfsabonnementen (zakelijk)

Abonnement	Richtprijs	Wat het toevoegt
Team	Vanaf ongeveer \$25/maand per standaardlicentie (\$20/maand jaarlijks); ongeveer \$125/maand per premiumlicentie (\$100/maand jaarlijks)	Centrale facturatie, beheeropties, SSO, een gedeelde werkruimte; alle modellen beschikbaar
Enterprise	Vanaf ongeveer \$20/licentie/maand plus kosten op basis van gebruik, jaarlijks gefactureerd	Alles uit Team, plus SCIM, auditlogs, een compliance-API, eigen regels voor gegevensbewaring, HIPAA-geschiktheid, toegang op basis van rollen

Het praktische verschil voor een bedrijf: met een Team- of Enterprise-licentie krijgt elke collega een eigen quotum, en de organisatie ziet het totale gebruik en bepaalt wie toegang heeft tot welke modellen en functies. Individuele Free-, Pro- of Max-abonnementen zijn persoonlijk, je beheert ze zelf, en ze worden niet centraal beheerd.

9. Sessielimieten, weeklimieten en waar de resettijd vandaan komt

Betaalde abonnementen meten het gebruik op twee manieren tegelijk.

- Een sessievenster van 5 uur. Het start op het moment dat je je eerste bericht stuurt, en elk bericht in de 5 uur daarna telt mee voor hetzelfde venster, of het nu één lang gesprek is of meerdere aparte chats.
- Daarbovenop een weeklimiet: een groter quotum dat ongeveer wekelijks vernieuwt, meestal verdeeld in een algemene pot voor alle modellen plus een kleinere pot speciaal voor het zwaarste model in je abonnement.

Waar de exacte dag en het uur van je persoonlijke reset vandaan komen: Anthropic publiceert geen vaste, wereldwijde klok die ieders weeklimiet op hetzelfde moment reset. Het verschilt per account, en de exacte aftelling zie je onder Settings, daarna Usage. In de praktijk werkt het als een schuivend venster dat vastligt op het moment waarop je huidige weekcyclus begon, en niet als een vast moment in de kalender, zoals elke maandag om 00:00 UTC. Sommige gebruikers melden dat de reset iets vroeger komt dan precies 7 keer 24 uur later. Beschouw de aftelling in de app dus als de waarheid voor je eigen account, niet als iets wat je zelf kunt uitrekenen.

Het is ook nuttig om drie verschillende dingen uit elkaar te houden die allemaal sessie worden genoemd.

- De sessie van 5 uur voor de gebruikslimiet hierboven: een begrip voor facturatie en quotum.
- Eén gesprek of taaksessie, die veel langer dan 5 uur echte tijd kan duren, terwijl alleen de berichten die je er echt in stuurt van je gebruik afgaan.
- Het contextvenster van een model: hoeveel tekst, input en output samen, in één gesprek past voordat oudere inhoud samengevat of weggelaten moet worden. Dit is een limiet op grootte, geen limiet in de tijd en geen limiet die vernieuwt.

10. Modellen veranderen, en nieuwere modellen kunnen een quotum snel opgebruiken

Geen van de vier modellen in deze gids is blijvend. Anthropic haalt oudere versies geleidelijk uit dienst en vervangt ze door nieuwe, zoals Opus 5.5 Opus 5 verving, en Sonnet 5.5 Sonnet 5. Haiku 4.5 is bijvoorbeeld maar gegarandeerd tot 15 oktober 2026. Zodra een versie uit dienst is, kun je ze uiteindelijk helemaal niet meer gebruiken, ook al staat ze misschien nog in een ouder document zoals dit. Zie elke tabel hierboven als een momentopname, niet als een vaste referentie; controleer platform.claude.com/docs/en/models best om de paar maanden opnieuw.

VALKUIL — Een nieuwer, krachtiger model kan een weekquotum snel opgebruiken

Het gebeurt echt vaak: je probeert het nieuwste topmodel (nu Fable) op een open taak in veel stappen, en ziet een groot deel van je weekquotum verdwijnen in ruim minder dan een uur, soms binnen enkele minuten. Het kost immers meer per token en werkt zonder pauze door via veel tool-aanroepen.

De praktische les: de eerste keer dat jij of je team een nieuwer of krachtiger model gebruikt voor een taak zonder toezicht of een lange taak, hou je Settings, daarna Usage open en kijk je de eerste minuten mee. Ga er niet van uit dat het zich gedraagt zoals het model dat je gewend bent.

11. Zelfstandige agents: waarom de maandfactuur sneller kan stijgen dan verwacht

Alles tot nu toe gaat ervan uit dat een persoon elk bericht stuurt. Zodra een agent zichzelf start, zoals een geplande taak of een terugkerende workflow, gaan de kosten niet meer over één gesprek. Ze worden een vermenigvuldiging van drie dingen die elk apart kunnen veranderen: hoe vaak de agent draait, hoeveel tokens hij per keer gebruikt, en welk model het werk doet.

Elke factor op zich kan een grote vermenigvuldiger zijn. Van één keer per dag naar elke 15 minuten gaan is alleen al 96 keer vaker. Dezelfde terugkerende taak van Haiku naar Fable verplaatsen maakt de prijs per token alleen al tot 10 keer hoger. Omdat deze factoren vermenigvuldigen in plaats van optellen, tel je de twee effecten niet op als je beide tegelijk verandert; je vermenigvuldigt ze. Zo kan een klein, goedkoop ogend experiment uitdraaien op een factuur die honderden keren hoger is, zonder dat iemand dat bewust heeft beslist.

Een vierde factor maakt dit nog makkelijker te onderschatten: het aantal tokens per keer ligt zelden vast. Een agent die tools aanroept, bestanden leest of bij elke run een groeiende geschiedenis opnieuw stuurt, kan per keer veel meer tokens gebruiken dan een eenvoudige eenmalige prompt, en dat aantal groeit meestal tijdens het leven van de agent in plaats van constant te blijven.

VALKUIL — Twee verschillende manieren waarop het misloopt

Een agent op een abonnementslicentie gebruikt hetzelfde quotum van 5 uur en per week als interactief gebruik, en kan het team voor de rest van de week buitensluiten. Een agent op de API heeft zo'n plafond niet, dus het risico wordt dan een factuur zonder bovengrens.

TIP — Voor je iets volgens een planning laat draaien

Gebruik het lichtste model dat de terugkerende taak betrouwbaar uitvoert, zet prompt caching aan voor grote vaste context, en controleer vroeg hoeveel tokens elke run echt gebruikt.

12. Wat je verder nog moet weten

- Contextvenster en gebruikslimiet zijn twee verschillende plafonds. Het ene begrenst hoeveel er in één gesprek past; het andere begrenst hoeveel je over een bepaalde tijd kunt sturen.
- Gebruik via de API of als ontwikkelaar valt helemaal niet onder de limieten van 5 uur of per week; je betaalt per token wat je gebruikt, zonder plafond. Het risico is daar dus een hoge factuur, niet buitengesloten worden.
- Rate limits, dus verzoeken per minuut en tokens per minuut, zijn een aparte beperking aan de kant van de API, bovenop de kosten per token.
- Beeld- en bestandsinput zoals afbeeldingen, PDF's en schermafbeeldingen gebruiken ook tokens, soms heel veel voor een grote afbeelding of een lange PDF.
- De omgang met gegevens verschilt per abonnement. Enterprise biedt eigen regels voor gegevensbewaring en HIPAA-geschiktheid, Free, Pro en Max niet.
- Beheerders van Team en Enterprise krijgen een gebruiksdashboard voor de hele organisatie om uitgaven en activiteit te zien. Bij een individueel abonnement ziet alleen die persoon zijn eigen gebruik.

De cijfers zijn gecontroleerd met de officiële pagina's van Anthropic op de datum op de voorpagina. Controleer claude.com/pricing voor je een abonnement kiest: namen, prijzen en limieten veranderen vaak.